

YZM0206 LAB 10:

Uygulama:

Bu ders kapsamında işlediğimiz aşağıda listelenen bazı denetimli öğrenme algoritmalarını kabaca uygulama fırsatı bulacağınız bu laboratuvarı, elinizde Social_Network_Ads.csv veri seti ve bu veri seti üzerinde çalışan 5 farklı sınıflandırma algoritmasının kod taslağı bulunmaktadır. Sınıflandırmayı bu kodlar ve size verilen örnek taslak dosyasını inceleyerek başlatın. Aşağıdaki tabloyu inceleyerek ve elinizdeki Python kodlarını (Logistic Regression, K-NN, Naive Bayes, vb.) kullanarak (geliştirerek), veri setinizin özelliklerine göre en uygun algoritmayı, o algoritmaya ait en uygun hiperparametreleri deneyerek seçin ve verdiğiniz karar sonrası neden o parametreleri kullandığınızı veri seti üzerinden nedenleriyle açıklayın.

Sınıflandırma Modeli	Avantajlar	Dezavantajlar
Logistic Regression	Olasılıksal yaklaşım, özelliklerin istatistiksel önemi hakkında bilgi verir.	Lojistik Regresyon Varsayımları
K-NN	Anlaması basit, hızlı ve verimlidir.	Komşu sayısı k'nin seçilmesi gerekir.
Naive Bayes	Verimli, aykırı değerlerden etkilenmez, doğrusal olmayan problemlerde çalışır.	Özelliklerin aynı istatistiksel öneme sahip olduğu varsayımına dayanır.
Decision Tree	Yorumlanabilirlik, ölçeklendirme gerektirmez, hem doğrusal hem doğrusal olmayan problemlerde çalışır.	Küçük veri setlerinde kötü sonuçlar, kolayca aşırı öğrenme (overfitting) oluşabilir.
Random Forest	Güçlü ve doğru, doğrusal olmayanlar dahil birçok problemde iyi performans verir.	Yorumlanamaz, aşırı öğrenme kolayca oluşabilir, ağaç sayısının seçilmesi gerekir.


Deney sonunda dönem boyunca öğrendiğiniz teorik ve pratik bilgiler ışığında aşağıdaki tabloyu doldurun. Yorumlarınız tutarlı ve detaylı olsun. Her bir algoritma için karmaşıklık matrisi çizilsin ve tabloya o çizimlerden elde edilen değerler işlensin. En son ders işlenen Rastgele Orman Algoritması bu derste bilhassa üstünde durmanız gereken algoritma olduğu için onu koyu yazıp vurguladım. Laboratuvarıda sormasam da SVM (Support Vector Machines) yani Destek Vektör Makineleri Algoritmasını da dilerseniz uygulayabilirsiniz. Analizleriniz sırasında her bir algoritmayı ne kadar detaylı ve derinlemesine analiz ederseniz vardığınız yargı o derece isabetli olacaktır. Her algoritmaya ait py dosyasını ilgili analizleri içerek şekilde güncelleyin.

Sınıflandırma Modeli	Doğruluk (Accuracy)	Confusion Matrix (TN, FP, FN, TP)	Elde Edilen Sonuç Yorumunuz
Logistic Regression			
K-NN			
Naive Bayes			
Decision Tree			
Random Forest			


Uyarı: Lütfen elinizde veri setini EDA mantığıyla analiz ederek işe başlayın.

1. Keşifsel Veri Analizi (EDA) Grafikleri


Yaş Dağılımı:




Tahmini Maaş Dağılımı:



Satın Alma Hedef Dağılımı:



Yaş ve Maaş İlişkisinin Satın Almaya Göre Dağılımı:



EDA analizinden elde edilen bulgular: Yaş ve Maaş özelliklerinin dağılımına (Scatter Plot) bakıldığında, 'Satın Alanlar' ile 'Satın Almayanlar' arasında doğrusal bir sınır yoktur. Bu sebeple doğrusal modeller (Lojistik Regresyon) zayıf kalacak, ağaç tabanlı veya K-NN modelleri yüksek başarı gösterecektir.

2. Modellerin Analizi (Karşılaştırma Tablosu)

Sınıflandırma Modeli	Doğruluk (Accuracy)	Confusion Matrix	Yorumunuz
Logistic Regression	89.00%	TN: 65, FP: 3, FN: 8, TP: 24	Model, veriyi doğrusal (linear) bir çizgiyle ayırmaya çalıştığından kıvrımlı yapıya uyum sağlayamaz. Hata oranı yüksektir.
K-NN	93.00%	TN: 64, FP: 4, FN: 3, TP: 29	Doğrusal olmayan karmaşık sınırları iyi kavradığı için doğruluk oranı yüksektir.

Naive Bayes	90.00%	TN: 65, FP: 3, FN: 7, TP: 25	Yaş ve maaşın birbirinden bağımsız dağıldığı varsayımı üzerine çalışır. Sonuçları tatmin edicidir.
Decision Tree	94.00%	TN: 64, FP: 4, FN: 2, TP: 30	Veri setini çok iyi öğrenir. max_depth=3 ile kısıtlanarak overfitting engellenmiştir.
Random Forest	93.00%	TN: 64, FP: 4, FN: 3, TP: 29	Dönem boyunca üzerinde durulan ve bu problemdeki en güçlü algoritmadır. 200 Karar Ağacı birleştirilerek kullanılmıştır. Overfittingi engeller ve en tutarlı/istikrarlı tahminleri sunar.